

Speeded-Up Robust Features (SURF)

El algoritmo SURF (Speeded-Up Robust Features) es un método utilizado en visión por computadora para detectar y describir características en imágenes. La detección de características se refiere a la identificación de puntos clave en una imagen, como bordes, esquinas o regiones distintivas, que pueden ser utilizados para describir y comparar imágenes entre sí. La descripción de características se refiere a la extracción de información de cada punto clave, que puede ser utilizada para comparar puntos clave en diferentes imágenes.

La detección de características en SURF se realiza mediante un enfoque basado en la identificación de áreas de alta variación de intensidad en la imagen. Esto se logra mediante el uso de un detector de bordes de Moravec modificado, que calcula la variación de intensidad en diferentes direcciones alrededor de cada píxel. Los puntos clave se definen como los puntos en la imagen con las mayores variaciones de intensidad en su vecindario.

La descripción de características en SURF se realiza mediante el uso de un descriptor de características basado en filtros de onda Haar. El descriptor de características mide la distribución de intensidades de píxeles en el vecindario de cada punto clave en diferentes escalas y orientaciones. Esto se logra mediante el cálculo de la transformada de Fourier rápida (FFT) de las respuestas de los filtros de onda Haar para cada punto clave.

El descriptor de características SURF se normaliza adaptativamente para mejorar la robustez del descriptor en diferentes condiciones de iluminación. Esto se logra mediante el cálculo de la media y la desviación estándar de las intensidades de los píxeles en el vecindario del punto clave, y luego normalizando las intensidades de los píxeles en consecuencia.

La comparación de características en SURF se realiza mediante el uso de un criterio de distancia entre descriptores de características. El criterio de distancia se utiliza para determinar si dos puntos clave en diferentes imágenes corresponden entre sí. SURF utiliza un enfoque de emparejamiento de características basado en el cálculo de la distancia Euclidiana entre descriptores de características.

En general, SURF es un algoritmo de detección y descripción de características en imágenes que utiliza técnicas matemáticas como la transformada de Fourier rápida y los filtros de onda Haar para describir características en diferentes escalas y orientaciones. La normalización adaptativa y el emparejamiento de características basado en la distancia Euclidiana mejoran la robustez y la precisión del algoritmo en diferentes condiciones de iluminación y variaciones de imagen.

Distancia de Mahalanobis

La distancia de Mahalanobis es una medida de distancia que tiene en cuenta las correlaciones entre las variables de un conjunto de datos, a diferencia de la distancia euclidiana que solo tiene en cuenta las diferencias individuales en cada variable. La distancia de Mahalanobis es muy útil en el análisis de datos multivariados, donde se desea medir la distancia entre dos puntos que tienen varias variables correlacionadas.

La distancia de Mahalanobis se define como:

$$d(x,y) = \sqrt{(x - y)^T * S^{-1} * (x - y)}$$

donde x y y son vectores de p variables, S es la matriz de covarianza de las p variables y S^{-1} es la inversa de S . La distancia de Mahalanobis es la distancia euclidiana entre dos vectores x y y después de que los vectores se hayan normalizado por su covarianza.

La matriz de covarianza S se calcula como:

$$S = (1/n) * (X - \mu)^T * (X - \mu)$$

donde X es una matriz de n observaciones de p variables, μ es el vector de medias de las p variables y T denota la transposición de matriz.

La distancia de Mahalanobis tiene la propiedad de ser invariante a la escala y la orientación. Es decir, si los datos se transforman linealmente, la distancia de Mahalanobis permanece igual. Además, la distancia de Mahalanobis es menor cuando los vectores x e y están más correlacionados. Esto es útil en aplicaciones donde se desea medir la distancia entre dos puntos de datos en un espacio multivariado en el que las variables están correlacionadas.

En resumen, la distancia de Mahalanobis es una medida de distancia que tiene en cuenta las correlaciones entre las variables de un conjunto de datos y es útil en el análisis de datos multivariados. La distancia de Mahalanobis se calcula utilizando la matriz de covarianza de los datos y es invariante a la escala y la orientación de los datos.

Criterio de información de Akaike

El criterio de información de Akaike (AIC, por sus siglas en inglés) es una medida utilizada en estadística para comparar modelos estadísticos. El AIC se basa en la teoría de la información y se utiliza para seleccionar el modelo que mejor describe

los datos, teniendo en cuenta tanto la bondad de ajuste del modelo como la complejidad del modelo.

La fórmula del AIC se define como:

$$AIC = -2 * \log(L) + 2 * k$$

donde L es la función de verosimilitud del modelo y k es el número de parámetros del modelo. La función de verosimilitud L mide la probabilidad de que los datos observados sean generados por el modelo. El número de parámetros k se refiere a la cantidad de parámetros ajustables del modelo. El AIC se calcula como la suma de dos términos, el primero mide la bondad de ajuste del modelo y el segundo mide la complejidad del modelo.

La fórmula del AIC se basa en la idea de que el mejor modelo es aquel que describe los datos de manera adecuada y tiene la menor cantidad de parámetros. El término $-2 * \log(L)$ mide la bondad de ajuste del modelo y se basa en la función de verosimilitud. Cuanto menor sea el valor de $-2 * \log(L)$, mejor será el ajuste del modelo a los datos. Por otro lado, el término $2 * k$ mide la complejidad del modelo. Cuanto mayor sea el número de parámetros k, mayor será la complejidad del modelo. El AIC trata de encontrar un equilibrio entre la bondad de ajuste del modelo y su complejidad.

El modelo con el valor de AIC más bajo se considera el mejor modelo. Sin embargo, la comparación de modelos utilizando el AIC no garantiza que el mejor modelo sea el modelo verdadero o el que mejor explica la realidad. El AIC solo es una herramienta para seleccionar el mejor modelo de entre los modelos comparados. Además, el AIC no es válido para comparar modelos con diferentes conjuntos de datos, ya que la función de verosimilitud es específica para cada conjunto de datos.